

SageMaker による MLOps 基盤提案

モデル開発・学習・評価・デプロイを標準化し、AIモデルを継続改善できる状態を作る。

現状の課題

開発・学習の課題

- モデル学習が個人の手元作業に寄りやすい
- どのデータ・設定・コードで学習したか追いつらい
- 評価、登録、デプロイの流れが標準化されていない

運用・改善の課題

- 本番反映してよいモデルか判断しづらい
- 運用後の失敗例を次の改善へ戻す流れが必要
- モデル改善を継続的に回す管理基盤が必要

これらの課題に対しては、モデルの学習・評価・デプロイ・監視を継続的に管理するMLOpsの考え方をを用いるのが適している。

MLOps によって目指す形

MLOpsでは、モデルを作って終わりではなく、学習・評価・デプロイ・監視・再学習までを継続的に回せる状態を目指す。

今回PJでは、分類・検知・セグメンテーション・インペイントなどのモデルを、個人作業ではなくチームで管理・改善できる状態にすることが目的である。

MLOps の標準フロー

教師データを用意する



モデルが学習できる形式に整える



モデルを学習する



モデルを評価する



基準を満たしたモデルを登録する



業務から呼び出せる形にデプロイする



運用結果を監視し、次の改善へ戻す


この標準フローをAWS上で実現するための中心基盤として、AWS SageMakerを提案する。

SageMaker について

SageMakerは、機械学習モデルの開発、学習、評価、登録、デプロイ、監視を行うためのAWSのマネージドサービスである。

できること	内容
学習	Training Jobでモデル学習を実行する
評価	Processing JobやPipelinesで評価処理を実行する
登録	Model Registryでモデルをバージョン管理する
デプロイ	Endpointなどで推論できる状態にする
監視	Model MonitorやData Captureで運用状況を確認する

SageMaker を用いた MLOps の実現方式



各項目の説明

01

データ準備

教師データをモデルが学習できる形式に整える。

02

学習

分類・検知・セグメンテーションなどのモデルを学習する。

03

評価

精度、速度、失敗傾向を確認し、業務利用に耐えるか見る。

04

基準判定

評価結果をもとに、本番候補にしてよいか判断する。

05

登録

承認済み候補としてモデルをバージョン管理する。

06

デプロイ

業務システムから呼び出せる推論エンドポイントとして公開する。

07

監視

本番利用中の入力傾向、推論結果、失敗例を確認する。

コストについて

課金対象	何に対して課金されるか
学習・前処理	使ったインスタンス種別と実行時間
常時起動のAPI	モデルをAPIとして起動している時間、処理量
バッチによる推論処理	大量データをまとめて処理するために使った計算資源と処理時間
ストレージ	保存したデータ量
MLOps管理	Pipeline、監視、ログなどの利用量

SageMakerは固定月額ではなく、使った分だけ料金が発生する。

AWS公式のコスト例

利用シナリオ	コスト例	内容
前処理・検証	\$0.3112	100GBデータを2台のml.m5.4xlargeで10分処理
モデル学習	\$2.38	4回の学習実行とデバッグ
バッチによる推論処理	\$2.88	4回のBatch Transformを各15分実行
Serverless推論	\$40.16/月	月1,000万リクエスト、各100ms、10GB処理
常時起動のAPI	\$305.881/月	2台のml.c5.xlargeで常時稼働 + 日次監視
モデル評価	\$1.48	Llama2 7Bの自動評価を45分実行

出典: AWS公式 Amazon SageMaker AI pricing / Pricing examples